
Attention Is All You Need

基于纯注意力机制的序列转导模型

Authors : Ashish Vaswani, Noam Shazeer, Niki Parmar et al.

Affiliation : Google Brain / Google Research

Venue : Neural Information Processing Systems (NIPS) 2017

Paper Reading Presentation

目录

- 一 研究背景与动机——序列建模的瓶颈与注意力革命
- 二 模型架构——Transformer 的核心设计
- 三 实验与结果——机器翻译及其他任务验证
- 四 总结与展望——贡献、局限与未来方向

报告提纲

- ① 研究背景与动机
- ② 模型架构
- ③ 实验与结果
- ④ 总结与展望

序列建模的主流范式

Section 1 – Introduction

在 Transformer 提出之前，循环神经网络（RNN）及其变体 LSTM、GRU 一直是序列建模领域的事实标准。语言模型、机器翻译、语音识别等任务几乎无一例外地依赖循环架构来捕捉时序依赖关系。编码器-解码器（Encoder-Decoder）框架的确立更是让 RNN 成为序列转导任务的基石。

然而，循环结构的固有特性——按时间步逐一计算隐状态——决定了它在长序列上面临严峻挑战：梯度消失使得模型难以学习远距离依赖，而顺序计算则彻底阻断了训练时的并行化可能，导致计算效率随序列长度线性下降。

核心瓶颈：RNN 的顺序性使其无法并行化， $O(n)$ 的串行步骤成为长序列建模的根本性限制。即便引入注意力机制作为辅助，循环骨架的这一局限仍然无法被消除。

注意力机制的发展脉络

Section 1 – Background: Attention in Seq2Seq

注意力机制最早由 Bahdanau et al. (2014) 引入序列到序列模型中，用于解决长编码向量的信息瓶颈问题。其核心思想是允许解码器在每个时间步动态聚焦源序列的不同位置，而非仅依赖最终隐状态。

经典的加性注意力计算形式为：

$$\text{Attention}(\mathbf{q}, \mathbf{K}, \mathbf{V}) = \sum_i \alpha_i \mathbf{v}_i, \quad \alpha_i = \frac{\exp(e_i)}{\sum_j \exp(e_j)}, \quad e_i = \text{score}(\mathbf{q}, \mathbf{k}_i)$$

尽管注意力机制显著提升了翻译质量，但在 2017 年之前它始终被视为 RNN 的辅助组件——用于增强信息流动，而非替代循环结构本身。没有人尝试过完全抛弃循环和卷积，构建一个纯注意力模型。

本文核心贡献

Section 1 – Contribution Statement

Vaswani et al. 在本文中提出了一个大胆的假设：注意力机制本身已经足够强大，可以独立承担序列转导的全部建模任务，无需循环、无需卷积。基于这一假设，作者设计了 **Transformer** 架构——一个完全依赖自注意力（Self-Attention）机制的编码器-解码器模型。

该模型在 WMT 2014 英德翻译任务上达到 28.4 BLEU，超越所有已有模型（包括集成模型）；在英法翻译上达到 41.8 BLEU 的新纪录，且训练成本仅为前最优模型的一小部分。

Transformer：首个完全基于注意力的序列转导模型——抛弃循环与卷积，以 $O(1)$ 的顺序操作数连接任意两个位置，实现完全并行化训练。

报告提纲


- ① 研究背景与动机
- ② 模型架构
- ③ 实验与结果
- ④ 总结与展望

整体架构：编码器-解码器

Section 3 – Model Architecture (Figure 1)

Transformer 保留了经典的编码器-解码器宏观结构。编码器将输入符号序列 $(x_1, \dots, x_n)$ 映射为连续表示 $\mathbf{z}$ ；解码器基于 $\mathbf{z}$ 自回归地生成输出 $(y_1, \dots, y_m)$ 。

- 编码器 $N=6$ 层，每层含多头自注意力 + 前馈网络
- 解码器 $N=6$ 层，额外增加交叉注意力子层
- 每个子层：残差连接 + 层归一化



Transformer 编码器-解码器架构

缩放点积注意力

Section 3.2.1 – Scaled Dot-Product Attention

注意力函数的本质是将一个 Query 与一组 Key-Value 对映射为输出。Transformer 采用缩放点积注意力 (Scaled Dot-Product Attention)，其计算效率远高于加性注意力，且可充分利用矩阵乘法硬件加速。

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^{\top}}{\sqrt{d_k}}\right) V$$

缩放因子 $1/\sqrt{d_k}$ 的引入至关重要：当 d_k 较大时，点积的量级随维度增长，导致 softmax 进入梯度极小的饱和区域。除以 $\sqrt{d_k}$ 可将方差归一化至 1，使梯度保持在有效区间，确保训练稳定性。

多头注意力机制

Section 3.2.2 – Multi-Head Attention

单一注意力函数只能学习一种“关注模式”。为了让模型同时从不同表示子空间捕获信息，Transformer 引入了多头注意力——将 Q 、 K 、 V 分别线性投影 h 次，在每个投影空间中独立计算注意力，最后拼接并投影：

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) W^O$$
$$\text{where } \text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V)$$


本文使用 $h=8$ 个头，每个头的维度为 $d_k = d_v = d_{\text{model}}/h = 64$ 。由于每个头的维度降低，多头注意力的总计算量与全维度单头注意力几乎相同，但表达能力显著增强。

多头注意力的并行投影机制

Section 3.2.2 – Multi-Head Attention (Figure 2)

多头注意力将 Q, K, V 分别通过 h 组不同的线性投影映射到低维子空间，在每个子空间独立执行注意力计算后拼接。

这一设计允许模型同时关注不同位置的不同表示子空间——某些头可能学习句法依赖，另一些则捕捉语义关联。



编码器层的内部结构

Section 3.1 – Encoder

编码器由 $N=6$ 个结构相同的层堆叠组成。每一层的前向计算包含两个子层，且在每个子层周围都套用了相同的“包裹”策略来稳定深层训练。

- **子层 1：多头自注意力**——所有 Query、Key、Value 均来自前一层输出，模型借此对输入序列中任意两个位置建立直接依赖
- **子层 2：位置前馈网络**——两层全连接 $\text{FFN}(x) = \max(0, xW_1 + b_1)W_2 + b_2$ ，隐层维度 $d_{\text{ff}}=2048$ ，逐位置独立作用
- **残差 + 层归一化**——每个子层的输出为 $\text{LayerNorm}(x + \text{Sublayer}(x))$ ，残差连接使梯度直通深层，LayerNorm 控制激活尺度

为兼容残差路径，模型所有子层及嵌入层的输出维度统一为 $d_{\text{model}}=512$ 。这一设计使得层数的增加不会改变张量形状，模块可任意堆叠。

位置编码

Section 3.5 – Positional Encoding

Transformer 完全抛弃了循环与卷积，因此对输入序列没有任何固有的位置感知能力。为弥补这一缺陷，模型在输入嵌入上叠加了正弦位置编码，向每个位置注入唯一的位置信号。

$$PE_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right), \quad PE_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right)$$

正弦编码的关键优势在于：对于任何固定偏移量 k ， PE_{pos+k} 可以表示为 PE_{pos} 的线性函数，因此模型可以轻松学习相对位置关系。此外，正弦编码使模型能够外推到训练中未见过的更长序列长度，无需额外学习参数。

为什么选择自注意力?

Section 4 – Why Self-Attention (Table 1)

自注意力与循环层、卷积层相比，在三个关键维度上具有优势：每层计算复杂度、可并行化程度、以及最长路径长度（学习远距离依赖的难度）。

层类型	每层复杂度	顺序操作数	最长路径
Self-Attention	$O(n^2 \cdot d)$	$O(1)$	$O(1)$
Recurrent	$O(n \cdot d^2)$	$O(n)$	$O(n)$
Convolutional	$O(k \cdot n \cdot d^2)$	$O(1)$	$O(\log_k n)$
Self-Attn (restricted)	$O(r \cdot n \cdot d)$	$O(1)$	$O(n/r)$

当序列长度 $n < d_{\text{model}}$ 时（如典型句子长度），自注意力在计算量上也优于循环层。更重要的是，其 $O(1)$ 的最长路径使任意位置间的信息传递无需中间步骤。

从设计到验证

Transition

至此，Transformer 的核心设计已经完整呈现：完全并行化的自注意力取代了循环计算，多头机制赋予模型多视角表示能力，残差与归一化保障了深层训练的稳定性，正弦编码注入了位置信息。

接下来的关键问题是：这一纯注意力架构能否在实际任务中匹配甚至超越经过多年优化的 RNN/CNN 模型？

验证策略：作者选择机器翻译（WMT 2014 EN-DE & EN-FR）作为主实验，辅以消融实验解析各设计决策的贡献，并在英语成分句法分析上测试泛化能力。

报告提纲

- ① 研究背景与动机
- ② 模型架构
- ③ 实验与结果**
- ④ 总结与展望

训练配置

Section 5.1 – Training Data and Batching; Section 5.2 – Hardware and Schedule

训练数据方面，英德翻译使用 WMT 2014 数据集中约 450 万句对，采用 BPE 编码构建约 37000 词的共享词表；英法翻译则使用更大规模的 3600 万句对，词表大小约 32000。句对按近似长度分组为 batch，每个 batch 包含约 25000 个源语言 token 和 25000 个目标语言 token。

硬件方面，模型在 8 块 NVIDIA P100 GPU 上训练。基础模型 ($d_{\text{model}}=512$) 的每个训练步耗时约 0.4 秒，共训练 100K 步 (约 12 小时)；大模型 ($d_{\text{model}}=1024$) 每步约 1.0 秒，训练 300K 步 (约 3.5 天)。

优化器使用 Adam ($\beta_1=0.9$, $\beta_2=0.98$, $\epsilon=10^{-9}$)，并采用作者提出的 warmup 学习率调度：前 4000 步线性增加学习率，之后按步数的平方根倒数衰减。正则化则结合了残差 Dropout ($P_{\text{drop}}=0.1$) 和标签平滑 ($\epsilon_{\text{ls}}=0.1$)。

机器翻译结果

Section 6.1 – Machine Translation (Table 2)

在 WMT 2014 测试集上，Transformer 与当时的最优模型进行了全面对比。结果表明其在翻译质量和训练效率上均取得了显著突破。

模型	类型	EN-DE BLEU	EN-FR BLEU
ByteNet	CNN	23.75	—
Deep-Att + PosUnk	RNN+Attn	—	39.2
GNMT + RL	RNN+Attn	24.6	39.92
ConvS2S	CNN	25.16	40.46
Transformer (base)	Self-Attn	27.3	38.1
Transformer (big)	Self-Attn	28.4	41.8

Transformer (big) 在英德上超越此前最优 +2.0 BLEU，英法上达到 41.8 BLEU 的新纪录，且训练成本仅为前最优模型的 1/4。

结果解读

Section 6.1 – Analysis

Transformer 的成功不仅仅体现在 BLEU 分数的绝对值上。更值得关注的是“效率-质量”的帕累托前沿被大幅前移：此前 RNN 集成模型需要数周训练才能达到的精度水平，现在一个单模型在 3.5 天内即可超越。

这一效率提升直接来源于自注意力的并行性：所有位置对的交互在一次矩阵运算中完成，无需像 RNN 那样逐步展开。GPU 的大规模并行计算能力被充分释放，训练吞吐量数倍于同规模的循环模型。

核心启示：Transformer 证明了“更简单的架构 + 更高效的计算利用 = 更好的结果”这一工程范式。模型质量的提升不再依赖于更复杂的结构设计，而是依赖于更大的有效训练规模。

消融实验

Section 6.2 – Model Variations (Table 3)

为量化各设计决策的贡献，作者在英德 newstest2013 开发集上系统地变化了模型超参数，观察性能变化。

变体	h	d_k	d_{model}	BLEU
Base (参考)	8	64	512	25.8
单头注意力	1	512	512	24.9
过多头 (16 头)	16	32	512	25.5
d_k 减小	8	32	512	25.2
模型增大	16	64	1024	26.2
无位置编码	8	64	512	24.5
可学习位置编码	8	64	512	25.7

关键发现：注意力头数影响显著（单头下降 0.9）、位置编码不可或缺（去除后下降 1.3）、正弦编码与可学习编码效果相当。

消融实验的启示

Section 6.2 – Discussion

消融实验揭示了 Transformer 设计空间中的若干重要规律。首先，多头注意力的价值在于多样性而非单纯的容量：8 头优于 1 头不是因为参数更多（总计算量相同），而是因为 8 个独立的注意力模式能够同时捕捉不同类型的语言关系——位置关系、句法关系、语义关系等。

其次， d_k 的选择需要在“注意力锐度”与“计算效率”之间取得平衡。过小的 d_k 导致区分度下降（不同 Key 之间的点积差异变小），而过大则意味着头数必须减少。 $d_k=64$ 恰好在这两端之间找到了甜蜜点。

最后，位置编码的消融实验（-1.3 BLEU）有力证明了位置信息对序列建模的必要性——纯注意力机制本身是排列不变的，没有位置编码的 Transformer 等价于一个“词袋模型 + 全局交互”，丧失了处理语序的能力。

英语成分句法分析

Section 6.3 – English Constituency Parsing (Table 4)

为验证 Transformer 在翻译以外任务上的泛化能力，作者将其应用于英语成分句法分析——一个结构化预测任务，输出受制于强嵌套约束。

模型	WSJ 23 F1	训练数据
Vinyals & Kaiser (2015)	88.3	WSJ only
Dyer et al. (2016) – 判别式	91.7	WSJ only
Transformer (4 layers)	91.3	WSJ only
Zhu et al. (2013)	90.4	semi-supervised
Huang & Harper (2009)	91.3	semi-supervised
Transformer (4 layers)	92.7	semi-supervised

即使在仅 40K 训练句的 WSJ-only 设置下，4 层 Transformer 已达到 91.3 F1；利用半监督数据后达到 **92.7 F1**，证明了架构的跨任务普适性。

报告提纲

- ① 研究背景与动机
- ② 模型架构
- ③ 实验与结果
- ④ 总结与展望**

主要结论

Section 7 – Conclusion

本文的核心贡献可以凝练为以下三点，它们共同标志着序列建模范式的根本性转变：

1. 架构创新——首次证明了纯注意力机制足以完成序列转导任务，彻底消除了对循环和卷积结构的依赖，实现了 $O(1)$ 顺序操作的全并行训练
2. 性能突破——在机器翻译基准上以显著优势超越所有已有方法，WMT EN-DE +2.0 BLEU、EN-FR 达到 41.8 BLEU 新纪录，且训练成本大幅降低
3. 范式影响——Transformer 的成功开启了“预训练 + 微调”的大模型时代，BERT、GPT 系列、T5 等后续工作均以 Transformer 为基础架构，其影响远超机器翻译本身

未来方向

Section 7 – Future Work

作者在论文结尾展望了 Transformer 的多个延伸方向。首先是将注意力机制扩展到图像、音频和视频等非文本模态——这些信号具有巨大的输入规模，需要发展局部或稀疏的注意力变体来控制计算量。事实上，后续的 Vision Transformer (ViT) 和 Audio Spectrogram Transformer 已经部分实现了这一愿景。

其次是让生成过程更少顺序性。尽管 Transformer 的编码器实现了完全并行化，解码器仍然是自回归的——每次只生成一个 token。非自回归翻译 (Non-Autoregressive Translation) 和并行解码方法旨在打破这一瓶颈，以牺牲少量质量换取数倍解码加速。

作者还提出了将自注意力与局部约束结合的思路——这预示了后来的 Longformer、BigBird 等高效注意力架构，它们通过稀疏注意力模式将复杂度从 $O(n^2)$ 降低至 $O(n \log n)$ 或 $O(n)$ ，从而处理长达数万 token 的文档。

THANK YOU



Thank You!

Questions?